AI 大模型开发工程师 之大模型核心之算法

讲师: 李希沅

掌握大模型核心三要素



大模型核心之算法

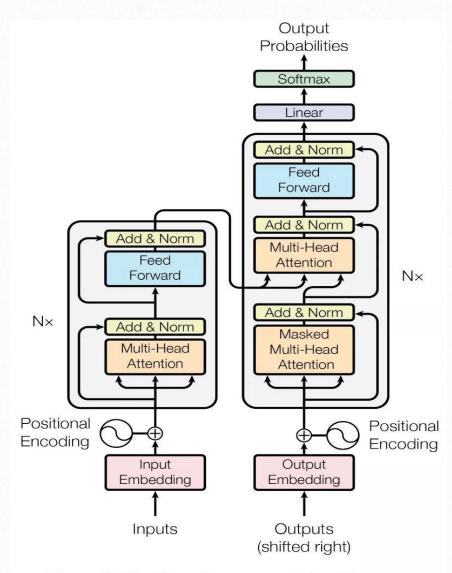


Figure 1: The Transformer - model architecture.

模型	结构	位置编码	激活函数	layer norm方法
原生 Transformer	Encoder- Decoder	Sinusoidal编码	ReLU	Post layer norm
BERT	Encoder	绝对位置编码	GeLU	Post layer norm
LLaMA	Casual decoder	RoPE	SwiGLU	Pre RMS Norm
ChatGLM-6B	Prefix decoder	RoPE	GeGLU	Post Deep Norm
Bloom	Casual decoder	ALiBi	GeLU	Pre Layer Norm

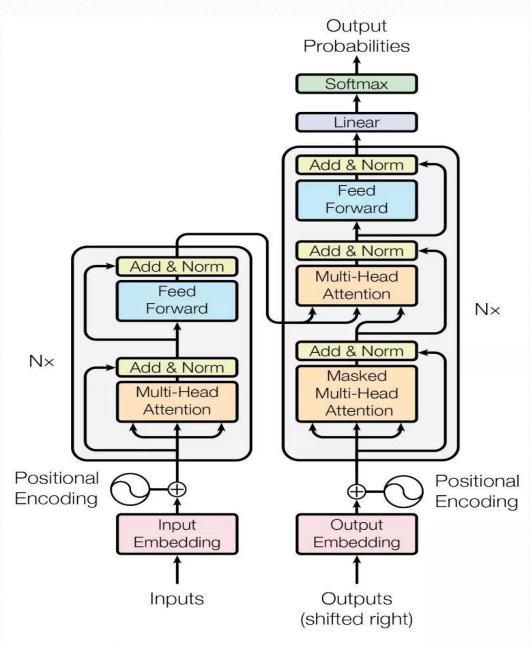
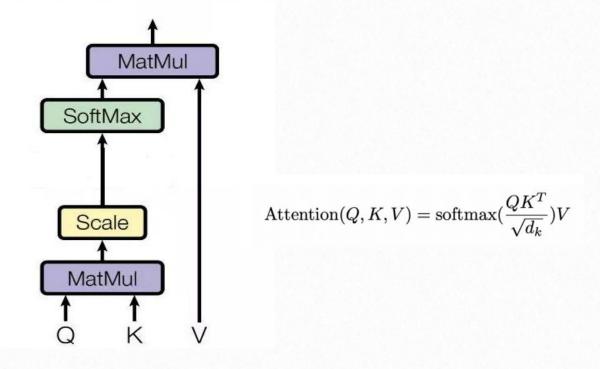
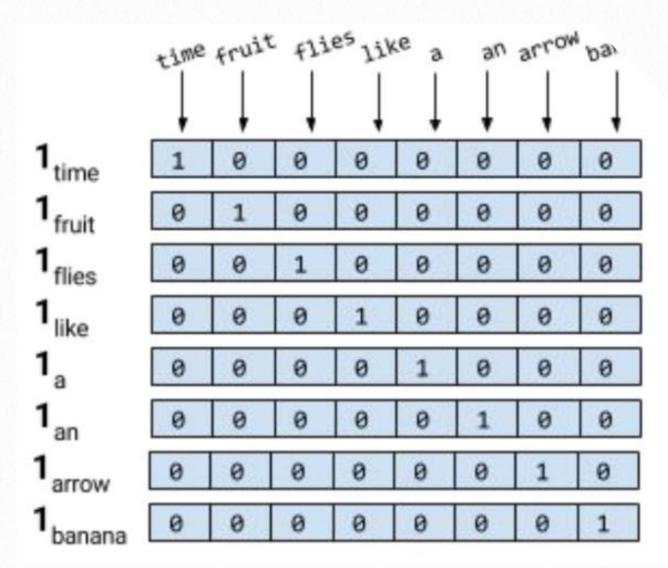


Figure 1: The Transformer - model architecture.



这里简单讲解除以 $\sqrt{d_k}$ 的作用:假设 Q,K 里的元素的均值为0,方差为 1,那么 $A^T=Q^TK$ 中元素的均值为 0,方差为 d。当 d 变得很大时,A 中的元素的方差也会变得很大,如果 A 中的元素方差很大(分布的方差大,分布集中在绝对值大的区域),**在数量级较大时,softmax 将几乎全部的概率分布都分配给了最大值对应的标签**,由于某一维度的数量级较大,进而会导致 softmax 未来求梯度时会消失。总结一下就是 S softmax S 的分布会和d有关。因此 S 中每一个元素乘上 $\frac{1}{\sqrt{d_k}}$ 后,方差又变为 1,并且 S 的数量级也将会变小。

独热编码 (one-hot 编码)



缺点1: 单词之间没关系

缺点2: 耗费存储

word2vec

Q 矩阵,对于任何一个独热编码的词向量都可以通过 Q 矩阵得到新的词向量

$$\begin{bmatrix} 0 & 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 17 & 24 & 1 \\ 23 & 5 & 7 \\ 4 & 6 & 13 \\ 10 & 12 & 19 \\ 11 & 18 & 25 \end{bmatrix} = \begin{bmatrix} 10 & 12 & 19 \end{bmatrix} \quad \triangle \stackrel{}{\not}{\not} (8)$$

优点1: 可以转换维度

优点2: 相似词之间的词向量之间也有了关系

有什么缺点?

ELMo 模型

有什么问题值得改进?

...very useful to protect banks or slopes from being washed away by river or rain...

...the location because it was high, about 100 feet above the bank of river...

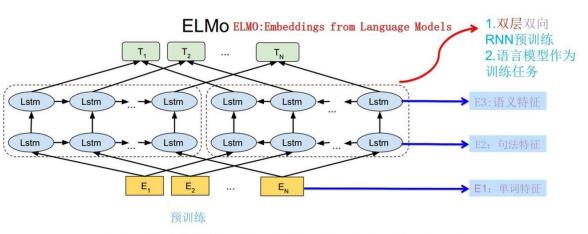
... The bank has plan to branch throughout the country...

... They throttled the watchman and robbed the bank...



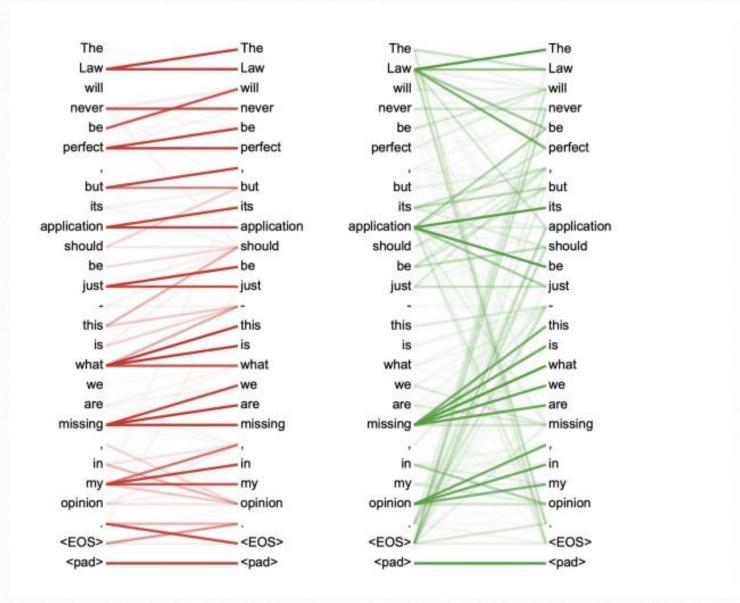


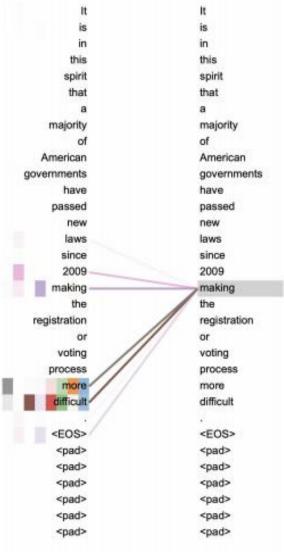
从WE到ELMO: 基于上下文的Embedding



NAACL 2018 最佳论文: Deep contextualized word representations

Multi-head Self Attention





谢谢观看